

COMPTE RENDU

26 janvier 2023

L'ESTIMATION DE L'ÂGE DES OTOLITHES PAR DES APPROCHES D'APPRENTISSAGE AUTOMATIQUE

Groupe:

Achiba Ahmed
Bougra Mohamed
EL Quartl Mouad
El Okri Amine
Zahdi Ghita

encadré par:

Emilie Poisson-Caillault

2023/2024

SECTION 1: Estimation de l'âge des poissons-épées

Les poissons-épées sont des poissons pélagiques de grande taille qui habitent les eaux profondes des océans mondiaux. Leur âge peut être déterminé en examinant leurs otolithes, des structures calcifiées situées dans leurs oreilles internes. Les otolithes se développent de manière régulière, formant une nouvelle couche chaque année. En comptant ces couches, l'âge du poisson peut être déterminé.

La méthode traditionnelle d'estimation de l'âge des poissons-épées implique l'examen visuel des otolithes par des experts humains. Cette approche, bien qu'efficace, présente des inconvénients tels que la lourdeur, le coût élevé et la possibilité d'erreurs humaines.

Approches d'apprentissage automatique

L'apprentissage automatique est une approche prometteuse pour l'estimation de l'âge des poissons-épées. Cette méthode utilise des données d'entraînement composées d'otolithes de poissons-épées dont l'âge est connu. Ces données servent à entraîner un modèle d'apprentissage automatique, qui est ensuite utilisé pour estimer l'âge des poissons-épées à partir de leurs otolithes.

Trois approches d'apprentissage automatique distinctes ont été proposées pour l'estimation de l'âge des poissons-épées :

K-Nearest Neighbors (KNN) : Identifie les K otolithes les plus proches dans l'espace des caractéristiques pour estimer l'âge de l'otolithe donné.

Random Forest : Construit un ensemble d'arbres de décision pour voter sur l'âge de l'otolithe donné, déterminant l'âge final en fonction des votes des arbres.

Multi-Layer Perceptron (MLP) : Utilise un réseau neuronal pour estimer l'âge de l'otolithe donné.

Avantages potentiels

Les approches d'apprentissage automatique offrent plusieurs avantages potentiels par rapport à la méthode traditionnelle d'estimation de l'âge des poissons-épées :

Réduction des coûts : L'automatisation du processus d'estimation de l'âge peut diminuer les coûts associés à cette tâche.

Amélioration de la précision : L'apprentissage automatique peut accroître la précision de l'estimation, en particulier pour les poissons-épées dont l'âge est difficile à déterminer à l'œil nu.

Augmentation de la cohérence : L'utilisation de l'apprentissage automatique peut contribuer à renforcer la cohérence des estimations d'âge, les modèles étant moins susceptibles de commettre des erreurs que les experts humains.

Perspectives

Les résultats des recherches menées sur l'utilisation de l'apprentissage automatique pour l'estimation de l'âge des poissons-épées sont prometteurs. L'utilisation de cette approche pourrait permettre d'améliorer l'efficacité et la précision de l'estimation de l'âge de ces poissons, ce qui aurait des implications importantes pour la recherche et la conservation.

SECTION 2 : Le Deep Learning et la segmentation d'images

La segmentation d'images est une tâche fondamentale en vision par ordinateur qui consiste à diviser une image en régions significatives. L'apprentissage profond a révolutionné ce domaine en permettant le développement de modèles précis et efficaces pour la segmentation d'images.

Techniques d'apprentissage profond pour la segmentation d'images

Les réseaux de neurones convolutionnels (CNN) sont les architectures d'apprentissage profond les plus couramment utilisées pour la segmentation d'images. Les CNN sont particulièrement bien adaptés à la capture des relations spatiales dans les images, ce qui les rend efficaces pour segmenter des objets aux limites complexes. D'autres architectures d'apprentissage profond, telles que les réseaux neuronaux récurrents (RNN) et les réseaux adversariaux, ont également été appliquées à la segmentation d'images avec des résultats prometteurs.

Applications de l'apprentissage profond dans la segmentation d'images

L'apprentissage profond a trouvé une large application dans divers domaines de la segmentation d'images, notamment :

Recherche d'images basée sur le contenu (CBIR): Les modèles d'apprentissage profond peuvent être utilisés pour récupérer des images en fonction de leur contenu, telles que des objets ou des scènes.

Imagerie médicale: L'apprentissage profond est utilisé pour segmenter les organes et les tissus dans les images médicales, aidant au diagnostic et à la planification des traitements.

Détection d'objets: Les modèles d'apprentissage profond peuvent identifier et localiser des objets dans des images, une capacité cruciale pour les véhicules autonomes et d'autres applications.

Criminalistique: L'apprentissage profond est employé pour extraire et analyser des informations d'intérêt médico-légal à partir d'images, telles que les empreintes digitales et les caractéristiques faciales.

Surveillance: Les modèles d'apprentissage profond peuvent être utilisés pour surveiller les séquences vidéo de surveillance à la recherche d'activités suspectes et d'identifier des individus.

Défis et perspectives d'avenir

Malgré les succès de l'apprentissage profond dans la segmentation d'images, il reste des défis à relever :

Gestion des données: La formation de modèles d'apprentissage profond nécessite de grandes quantités de données étiquetées, qui peuvent être coûteuses et longues à collecter.

Robustesse des modèles: Les modèles d'apprentissage profond peuvent être sensibles aux variations d'éclairage, de posture et d'autres facteurs, ce qui les rend moins robustes dans les applications du monde réel.

Biais algorithmique: Les modèles d'apprentissage profond peuvent refléter les biais présents dans les données d'entraînement, ce qui peut conduire à des résultats injustes ou discriminatoires.

Les perspectives d'avenir de l'apprentissage profond pour la segmentation d'images incluent :

Exploration de nouvelles architectures: Les chercheurs continuent de développer de nouvelles architectures d'apprentissage profond adaptées à des tâches de segmentation spécifiques.

Amélioration de l'interprétabilité: Rendre les modèles d'apprentissage profond plus interprétables peut aider les utilisateurs à comprendre leur processus de prise de décision et à identifier les biais potentiels.

Abordage des considérations éthiques et sociales: Les chercheurs doivent être conscients des implications éthiques et sociales de l'utilisation de l'apprentissage profond dans la segmentation d'images.

Conclusion

L'apprentissage profond a révolutionné la segmentation d'images, permettant le développement de modèles puissants et polyvalents. Cependant, il reste des défis à surmonter avant que l'apprentissage profond puisse être largement adopté dans les applications réelles. Des recherches continues sont nécessaires pour répondre à ces défis et faire progresser le domaine de l'apprentissage profond pour la segmentation d'images.

Section 2 : Estimation de l'âge des poissons à l'aide de techniques de Deep Learning.


L'estimation de l'âge des poissons joue un rôle crucial dans la gestion des ressources halieutiques. Traditionnellement effectuée par des experts humains, cette tâche peut être laborieuse et sujette à des variations. Cependant, le deep learning, une branche de l'intelligence artificielle, offre de nouvelles perspectives passionnantes pour automatiser ce processus. Dans cette étude, nous explorons comment les réseaux neuronaux convolutionnels (CNN) peuvent être utilisés pour estimer l'âge des poissons à partir d'images d'otolithes, ouvrant ainsi la voie à des méthodes plus rapides et potentiellement plus fiables.

2. Méthodologie et Matériaux

2.1. Collection du base de données :

La base de données utilisée dans cette étude comprend 5150 otolithes de morue de l'Atlantique prélevés lors de campagnes menées par l'Institut de recherche marine (IMR) entre 2012 et 2018, avec une détermination de l'âge réalisée par des lecteurs experts de morue. La méthodologie d'échantillonnage impliquait une sélection aléatoire stratifiée en fonction de la longueur des poissons pour chaque station de chalutage. Les otolithes couvrent une large gamme d'âges (1 à 13 ans) mais excluent les poissons de 0 an.

Pour augmenter le jeu de données d'entraînement, des techniques de rotation (de 0 à 360 degrés) et de réflexion par rapport à l'axe vertical ont été appliquées.



2.2. Implémentation et Entraînement du modèle:

Prétraitement du Base de Données

Les images d'entraînement, initialement de taille 3744×5616 pixels, ont été redimensionnées dans une plage allant de 380×380 à 528×528 pixels en fonction de l'architecture. Les valeurs des pixels, initialement comprises entre 0 et 255, ont été normalisées pour se situer entre 0 et 1. Les prédictions sur l'ensemble de test ont été effectuées sur des images redimensionnées à 380×380 et 384×384 pixels.

Pour chaque pli, l'âge a été normalisé sur l'ensemble d'entraînement en soustrayant la moyenne et en mettant à l'échelle pour obtenir une variance unitaire. Cette normalisation a ensuite été appliquée aux ensembles de validation et de test.

2- Modèle de l'entraînement des données :

Les CNN ont été sélectionnés en fonction de leurs performances sur le benchmark ImageNet et de la disponibilité d'implémentation open source avec des poids pré-entraînés. Deux architectures de Convolutional Neural Networks utilisées pour cette étude sont EfficientNetV1 et EfficientNetV2. Ces modèles visent à obtenir de meilleures performances avec moins de paramètres, les rendant plus efficaces sur le plan computationnel par rapport aux architectures CNN traditionnelles.

EfficientNetV1 :

Propose une méthode d'échelonnage composé qui ajuste uniformément la profondeur du réseau, la largeur et la résolution simultanément.

Équilibre la profondeur (nombre de couches), la largeur (nombre de canaux) et la résolution (taille de l'image d'entrée) pour optimiser les performances globales tout en maintenant l'efficacité.

EfficientNetV1 a été largement adopté comme base pour diverses tâches de vision par ordinateur.

EfficientNetV2 :

- Successeur d'EfficientNetV1, il améliore le modèle d'origine en introduisant des changements dans l'architecture et les principes d'échelonnage.
- Met l'accent sur de meilleures performances avec des tailles de modèle plus petites en utilisant une méthode d'échelonnage plus avancée pour la profondeur du réseau, la largeur et la taille de l'image.
- EfficientNetV2 maintient l'efficacité de son prédécesseur tout en obtenant des résultats de pointe dans diverses tâches.

Les deux EfficientNetV1 et EfficientNetV2 sont connus pour leur efficacité dans les tâches de classification d'images et ont été utilisés dans diverses applications, en particulier dans l'estimation automatique de l'âge des poissons à partir d'images d'otolithes.

La fonction de coût utilisée pour l'entraînement était l'erreur quadratique moyenne (MSE).

Le jeu de données, composé de 5150 otolithes, a été divisé en un ensemble d'entraînement de 90% (4635 otolithes) et un ensemble de test de 10% (515 otolithes). Une validation croisée à 10 plis a été appliquée sur l'ensemble d'entraînement pour maximiser l'utilisation des données. Chaque pli impliquait la rétention d'une partie différente pour la validation, tandis que le modèle était entraîné sur les parties restantes. Cela a abouti à l'entraînement de 10 modèles différents, chacun utilisant un ensemble distinct de 463 images pour la validation dans chaque pli. Le modèle avec la meilleure MSE parmi les 10 modèles a été sélectionné.

Hyperparamètres : Les hyperparamètres ajustés incluent la taille du lot, le taux d'apprentissage, la taille du pli, la décroissance du poids, la taille du pas, le nombre d'époques, l'arrêt précoce et la patience.

Métriques d'évaluation : Les métriques d'évaluation se concentraient sur la précision, mesurée en arrondissant les prédictions réelles à l'entier le plus proche et en déterminant la fraction d'otolithes où la classification d'âge correspondait aux étiquettes.

Comparaison des CNN avec les lecteurs humains : Les variations dans l'accord en pourcentage entre les classes d'âge ont montré des tendances similaires dans les prédictions basées sur les CNN et les lecteurs humains, avec un accord généralement décroissant avec l'âge.

Précision selon les groupes d'âge : Une distinction claire de la précision de prédiction a été observée entre les poissons plus jeunes et plus âgés basée sur les images d'otolithes.

Conclusion :

Les résultats démontrent que les techniques d'apprentissage profond ont un énorme potentiel pour extraire des informations d'âge à partir d'images d'otolithes. Les architectures de modèle standard, formées sur des données d'entraînement suffisantes spécifiques au cas d'utilisation, peuvent prédire avec précision l'âge à partir d'images d'otolithes. Les CNN soigneusement formés pourraient devenir un composant majeur dans les procédures nécessitant un traitement minimal et pourraient produire des estimations d'âge presque en mer. Les estimations d'âge algorithmiques pourraient également servir de référence utile pour évaluer les biais des lecteurs d'âge au sein et entre les laboratoires d'otolithes.

Section 4: Base de données:

1. Navire:

- Signification : Navire ou bateau.
- Objectif : Indiquer le nom ou l'identifiant du navire associé aux données. Il pourrait s'agir du navire de recherche ou du bateau de pêche qui a collecté les données.

2. Engin :

- Signification : Moteur ou engin de pêche.
- Objectif : Décrit le type d'engin de pêche ou de moteur utilisé dans la collecte des données.

3. Code_Espece :

- Signification : Code d'espèce.
- Objectif : Représente un code qui identifie la spécifique marine observée ou étudiée.

4. Type_Longueur :

- Signification : Type de mesure de longueur.
- Objectif : Spécifie le type de mesure de longueur utilisé (par exemple, longueur totale, longueur à la fourche) pour l'organisme marin.

5. Increment :

- Signification : Incrément de mesure.
- Objectif : Indique l'incrément de mesure utilisé pour enregistrer la taille de l'organisme marin.

6. Unite_Taille :

- Signification : Unité de longueur.
- Objectif : Spécifie l'unité de mesure de la longueur (par exemple, millimètres, centimètres).

7. Unite_Poids :

- Signification : Unité de poids.
- Objectif : Spécifie l'unité de mesure du poids (par exemple, grammes, kilogrammes).

8. Presentation :

- Signification : Présentation ou condition.
- Objectif : Décrit la condition ou la présentation de l'organisme marin (par exemple, entier, fileté).

9. Maturite_Echelle :

- Signification : Échelle de maturité.
- Objectif : Représente une échelle ou une classification pour évaluer la maturité de l'organisme marin.

10. Type_PC :

- Signification : Type d'otolithe.
- Objectif : Spécifie le type d'otolithe (structure de l'oreille interne) associé à l'organisme marin.

11. Preparation_PC :

- Signification : Préparation de l'otolithe.
- Objectif : Décrit la préparation spécifique de l'otolithe associée à l'organisme marin.

12. Poids_PC :

- Signification : Poids de l'otolithe.
- Objectif : Indique le poids de l'otolithe associée à l'organisme marin.

13. Cat :

- Signification : Catégorie.
- Objectif : Représente une classification catégorique ou un regroupement de l'organisme marin en fonction de certains critères.

14. Date :

- Signification : Date de l'observation ou de la collecte de données.
- Objectif : Spécifie la date à laquelle les données associées à l'organisme marin ont été collectées.

15. Numero_Trait :

- Signification : Numéro de trait.
- Objectif : Attribue un numéro ou un identifiant spécifique aux traits ou caractéristiques individuels de l'organisme marin.

16. Lieu :

- Signification : Lieu.
- Objectif : Indique l'endroit où l'organisme marin a été observé ou collecté.

17. Zone :

- Signification : Zone géographique.
- Objectif : Spécifie la zone géographique ou la région associée aux données.

18. Taille(mm) :

- Signification : Mesure de longueur en millimètres.
- Objectif : Représente la longueur de l'organisme marin mesurée en millimètres.

19. Taille :

- Signification : Mesure de longueur.
- Objectif : Représente la longueur de l'organisme marin, probablement dans l'unité spécifiée dans le champ "Unite_Taille".

20. Poids(g) :

- Signification : Mesure de poids en grammes.
- Objectif : Représente le poids de l'organisme marin mesuré en grammes.

21. Poids :

- Signification : Mesure de poids.
- Objectif : Représente le poids de l'organisme marin, probablement dans l'unité spécifiée dans le champ "Unite_Poids".

22. Sexe :

- Signification : Sexe de l'organisme.
- Objectif : Indique le genre ou le sexe de l'organisme marin.

23. Maturite :

- Signification : Statut de maturité.
- Objectif : Spécifie le statut de maturité de l'organisme marin.

24. Age :

- Signification : ge de l'organisme.
- Objectif : Représente l'âge de l'organisme marin.

25. Reference_Prelevement :

- Signification : Référence d'échantillonnage.
- Objectif : Fournit un identifiant de référence lié au processus d'échantillonnage ou de collecte de données.

26. Reference_PC :

- Signification : Référence de l'image d'otolithe.
- Objectif : Fournit un identifiant de référence lié à l'image de l'otolithe (structure de l'oreille interne) associée à l'organisme marin. Cette référence correspond probablement à une photo de l'otolithe prise lors du processus d'observation ou de collecte.